

# 20250627-多目标级联延迟反馈AIR双周会

## 🚩 Highlights

1. 学术数据集构建：按用户购买数差异化采样数据集产出完成，30d样本数4100w，转化率9.1%、复购率2.3%、退款率4.9%，符合预期；**仅保留购买用户数据 TODO**
2. **Base代码库**：开发torch版base，已集成ED-DFM, Defuse, Defer, FNW, Oracle等经典base，构造伪数据上跑通训练，待对齐现有数据集特征。
3. **净成交建模**：推导多目标重要性采样loss
4. **ECAD模型分析**：退款数据稀疏导致退款模型预测过度自信，从而引发净转化PCOC过低。

TODO:

数据集构建：2种数据集构建 [@李欣钰\(晚漾\)](#)

可联网开发机：[@产张明\(明言\)](#)

公开数据集方法 (criteo + 自己数据) : [@骆明轩\(洛谨\)](#)

1. 现有延迟反馈方法（不考虑假正样本）
2. 现有延迟反馈方法（考虑假正样本）
3. 进一步的方法探索

GMV模型：尝试现有延迟反馈方法 [@李欣钰\(晚漾\)](#)

## 学术数据集构建 [@李欣钰\(晚漾\)](#)

主表逻辑修正：

- 问题：一个adgroup\_id下有多个不同entity\_id，以及存在entity\_id='0'的数据
- 修正：添加筛选条件 entity\_source = 'item' and entity\_id != '0'

在sample数据前会将以下数据筛选：

```
ad_item_id IS NULL  
ad_item_id = '-'  
ad_item_id != entity_id
```

## u\_id筛选

- 方案一：

根据20250501-20250525期间，用户购买数量差异化采样

- 活跃用户：购买数量>5，随机取100万个
- 中等活跃用户：1<点击数量 < 5，随机取60万个
- 不活跃用户：点击数量 = 0，随机取40万个

每天数据只取筛选出的这200万个用户的数据。

- 筛选结果：

**总量 (20250501-20250525) :**

总记录数	购买数	复购数	退款数	购买率	复购率	退款率
41037005	3742731	946973	2015540	9.1204%	2.3076%	4.9115%

**每天数据量级：**

记录数：一百万

用户数：50万

购买数：10万（10%）

退款数：4万~10万

复购数：2万~5万



uid数据筛选\_差异采样.xlsx

57.4KB

- 方案二：

从20250401-20250430数据中找到有购买的用户

每天的数据从有购买的用户中sample

- 筛选结果：

20250501-20250525有购买的用户数: 79133648									
ds	total_records	total_user	pay_cnt	mul_pay_cnt	refund_cnt	pay_ratio	mul_pay_ratio	refund_ratio	
20250501	19696224	9597147	823688	95213	295110	4.1820%	0.4834%	1.4983%	
20250502	19979002	9727099	849673	99300	303685	4.2528%	0.4970%	1.5200%	
20250503	20276612	9912526	871347	102579	309494	4.2973%	0.5059%	1.5264%	
20250504	21662878	10483774	940230	111962	336787	4.3403%	0.5168%	1.5547%	
20250505	23853515	11441772	1096409	133416	393265	4.5964%	0.5593%	1.6487%	

**每天数据量在千万级，还需再采样**

### 再采样方式一：

- 根据用户购买数量，取前100万个用户的数据

#### 筛选结果(20250501-20250525)：

总记录数	购买数	复购数	退款数	购买率	复购率	退款率
45650219	2612713	682160	1580986	5.7233%	1.4943%	3.4633%

分析：购买率低可能是因为用户买的多，点的也多（用户购买率低）

### 再采样方式二：

- 根据用户购买率（购买数/点击数），取前2500万个用户的数据

#### 筛选结果(20250501-20250525)：

总记录数	购买数	复购数	退款数	购买率	复购率	退款率
41930460	8834022	1197282	2976438	21.0683%	2.8554%	7.0985%

方案二详细统计数据：



uid数据筛选\_有购买.xlsx

74.3KB

## 2. Base模型集成 @骆明轩(洛谨)

已经用criteo数据构建伪造数据已经集成好torch版本的ED-DFM,Defuse,Defer,FNW,Oracle等典型的base，退款相关的净转化标签预测等也已经写好逻辑。

具体进度：1.利用criteo数据集构造伪数据，加入退款时间戳。

2.集成ED-DFM,Defuse,Bi-Defuse,Defer,FNW,Oracle等典型的baseline的pytorch版本。

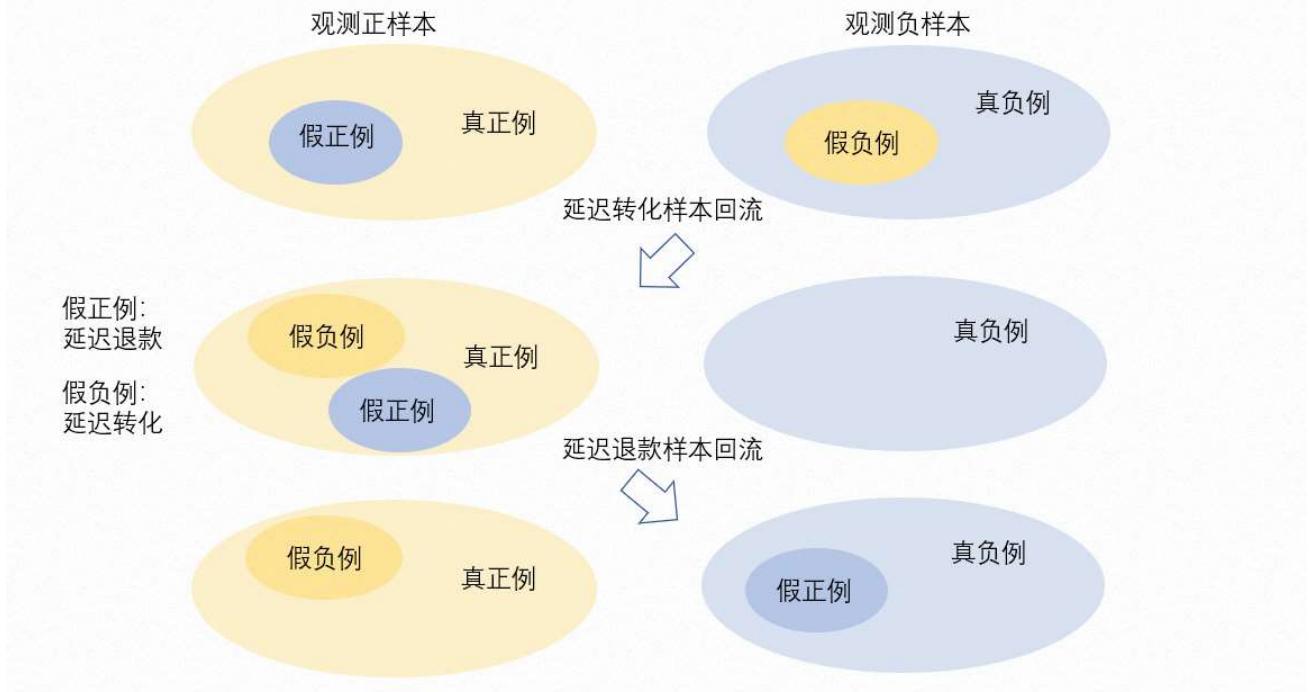
3.已经写好退款相关的净转化标签逻辑，差对齐现有的数据集特征

## 3. 净转化相关建模

参考defer的逻辑去推理退款相关的样本回补

	观测正样本	观测负样本	
第一次	真正例 + 假正例	真负例 + 假负例	

第二次	真正例 + 假正例 + 假负例	真负例	延迟转化样本纠正
第三次	真正例 + 假负例	真负例 + 假正例	延迟退款样本纠正



$$q(x, y=1) = p(x, y=1) + \frac{2}{3}P_{dr}(x) - \frac{1}{3}P_{dp}(x)$$

$$q(x, y=0) = p(x, y=1) + \frac{2}{3}P_{dp}(x) - \frac{1}{3}P_{dr}(x)$$

其中y是考虑退款后的延迟标签,q()指的是观测分布, p()指的是真实分布。  $P_{dr}(x)$ ,  $P_{dp}(x)$  分别是预测是延迟退款的概率, 以及是预测是延迟转化的概率

利用重要性采样

$$w^+ = \frac{p(x, y=1)}{q(x, y=1)} = \frac{p(x, y=1)}{p(x, y=1) + \frac{2}{3}P_{dr}(x) - \frac{1}{3}P_{dp}(x)}$$

$$w^- = \frac{p(x, y=1)}{q(x, y=1)} = \frac{p(x, y=1)}{p(x, y=1) + \frac{2}{3}P_{dp}(x) - \frac{1}{3}P_{dr}(x)}$$

$$L = - \sum_{x,y} [y \cdot w^+ \cdot \log(f_\theta(x)) + (1-y) \cdot w^- \cdot \log(1 - f_\theta(x))]$$

## 4. 上周模型TODO

trace分析ECAD refund rate学习情况

退款数据相对太稀疏导致退款模型预测过度自信，从而引发净转化PCOC过低。

取20250424~20250429的数据去做训练，取20250430的数据去做分析

cvr_auc	netcvr_auc	rfr_auc
0.8616864608702576	0.8651729509981683	0.8259705892288873

cvr_pcoc	netcvr_pcoc	rfr_pcoc
1.3709798549552554	0.7235422805301877	5.8811459529308

PCOC 不一致：一个偏高，一个偏低，说明两个模型的预测方向不一致。

RFR 模型 PCOC 异常偏高 (5.88)，说明模型对实际行为严重高估，应该是数据稀疏导致。在训练时，模型看到的正样本太少，容易把少量的正样本“放大”，认为这些特征更可能触发行为。如果正样本非常少，模型可能会过度依赖这些样本中的某些噪声特征。

做了这五天的数据统计，退款数据/转化数据 = 0.14355

退款数据/净转化数据 = 0.12553，而净转化数据/转化数据 = 0.87446.

因此猜测原本ECAD效果好可能强关联数据集，原本ECAD数据集退款数据比较稠密。而在现有的退款数据稀疏的情况下，不如直接建模净转化标签。

## 5. TO Discuss

1. ECAD 这种的 BDL baseline 是否需要比？
2. 多窗口定义是什么？是等待窗口，归因窗口，还是实际的转化退款窗口
3. GMV baseline 及 多窗口定义。
4. 这周跟林老师开会遗留的问题
  - i. 整合baseline的作用，后续是否准备出datasets文章以及benchmark文章
  - ii. 哪些方法比较容易做出来，1.online模型的迭代速度。2.online模型迭代考虑是否对齐旧模型。3.online模型迭代不做全量，而是做部分层的微调。4. online模型的强化学习。5.对于退款样本稀疏问题做上采样或者构造伪退款样本。6.online 模型的deploy。